## Die Aufgabe

Betrachte  $\Omega \subset \mathbb{R}^d$ . Für ein Modell  $f: \Omega \to \mathbb{R}$  konstruieren wir iterativ Approximationen  $s_f^{(n)}: \Omega \to \mathbb{R}$ , die f an n ausgewählte Daten  $x_1, ..., x_n \in \Omega$  interpolieren.

Sei  $k: \Omega \times \Omega \to \mathbb{R}$  ein positiv definiter Kern, sodass  $f \in \mathcal{H}_k(\Omega)$ . Hierbei bezeichnet  $(\mathcal{H}_k(\Omega), \langle \cdot, \cdot \rangle)$  den Raum von Funktionen  $f: \Omega \to \mathbb{R}^q$ , zu dem k der reproduzierende Kern ist, d.h. es gilt

- 1.  $k(\cdot, x) : \Omega \to \mathbb{R} \in \mathcal{H}_k(\Omega) \, \forall x \in \Omega$
- 2.  $\langle f, k(\cdot, x) \rangle = f(x) \, \forall x \in \Omega, f \in \mathcal{H}_k(\Omega)$

Für iterativ gewählte  $X_n:=\{x_1,...,x_n\}\subset\Omega$  konstruieren wir die Approximationen  $s_f^{(n)}$  als die orthogonale Projektion in

$$V(X_n) := \operatorname{span}\{k(\cdot, x_1), ..., k(\cdot, x_n)\} \subset \mathcal{H}_k(\Omega).$$

Dies ist die beste Approximation von f bezüglich  $\|\cdot\|_{\mathcal{H}_k(\Omega)}$ . Schreibe  $\langle\cdot,\cdot\rangle$  bzw.  $\|\cdot\|$  für das Skalarprodukt bzw. die Norm in  $\mathcal{H}_k(\Omega)$ . Gesucht sind also die Koeffizienten  $a_i$ , i=1,...,n sodass

$$s_f(x) = \sum_{i=1}^n a_i k(\cdot, x_i).$$

Diese finden wir mittels einer Orthonormalbasis  $(v_1, ..., v_n)$  von  $V(X_n)$ . Denn dann gilt

$$s_f(x) = \Pi_{V(X_n)}(f) = \sum_{i=1}^n c_i v_i,$$

wobei die  $c_i := \langle f, v_i \rangle$  die Koeffizienten der Linearkombination beschreiben und im n. Iterationsschritt können die bisher berechneten n-1 Basisfunktionen und Koeffizienten übernommen werden. Die Aufgabe des Algorithmus besteht also darin, im n. Iterationsschritt die n. Basisfunktion  $v_n \in V(X_n)$  und den dazugehörigen Koeffizienten  $c_n \in \mathbb{R}$  zu bestimmen.

Diese Überlegungen lassen sich leicht auf Funktionen  $f:\Omega\to\mathbb{R}^q$  für q>1 übertragen, in dem man den Algorithmus auf alle q Komponenten von f anwendet und den Raum

$$\mathcal{H}_k(\Omega)^q := \{ f : \Omega \to \mathbb{R}^q | (f)_j \in \mathcal{H}_k(\Omega) \}$$

betrachtet.

## Das Vorgehen

Sie  $\tilde{\Omega} \subset \Omega$  eine Diskretisierung von  $\Omega$ .

Mit  $P_{V(X_n)}$  bezeichnen wir die Power Function, die den Approximationsfehler der schlechtesten Funktion  $f \in \mathcal{H}_k(\Omega)$  an einer Stelle  $x \in \Omega$  im n. Iterationsschritt angibt:

$$P_{V(X_n)}(x) := \sup_{f \in \mathcal{H}_k(\Omega)} \frac{|f(x) - s_f^{(n)}(x)|}{\|f\|}.$$

Beim P-Greedy Algorithmus wird im n. Iterationsschritt, der Datenpunkt  $x_n$  ausgewählt, der die Power Function für den nächsten Iterationsschritt minimiert. Dieser liefert dann die n. Basisfunktion  $k(\cdot, x_n)$  bzw.  $v_n$ .

Lemma 1. Für alle  $x \in \Omega$  gilt

$$P_{V(X_n)}(x) = ||k(\cdot, x) - \Pi_{V(X_n)}(k(\cdot, x))||.$$

Beweis. Sei  $f \in \mathcal{H}_k(\Omega)$ , o.B.d.A. sei  $||f|| \leq 1$ . Außerdem sei  $v_1, ..., v_n$  eine Orthonormalbasis von  $V(X_n)$ . Für  $x \in \Omega$  und  $v_x := k(\cdot, x)$  gilt dann

$$f(x) - \Pi_{V(X_n)}(f)(x) = \langle v_x, f \rangle - \langle v_x, \sum_{i=0}^n \langle f, v_i \rangle v_i \rangle$$

$$= \langle v_x, f \rangle - \sum_{i=0}^n \langle f, v_i \rangle \langle v_x, v_i \rangle$$

$$= \langle v_x, f \rangle - \langle \sum_{i=0}^n \langle v_x, v_i \rangle v_i, f \rangle$$

$$= \langle v_x - \sum_{i=0}^n \langle v_x, v_i \rangle v_i, f \rangle$$

$$\leq \|v_x - \sum_{i=0}^n \langle v_x, v_i \rangle v_i \| \|f\|$$

$$\leq \|v_x - \Pi_{V(X_n)}(v_x)\|$$

Also muss für alle  $x \in \Omega$ 

$$P_{V(x_n)}(x) = \sup_{f \in \mathcal{H}_k(\Omega), ||f|| \le 1} |f(x) - \Pi_{V(X_n)}(f)(x)| \le ||v_x - \Pi_{V(X_n)}(v_x)||$$
Da für  $f := \frac{v_x - \Pi_{V(X_n)}(v_x)}{||v_x - \Pi_{V(X_n)}(v_x)||} \in \mathcal{H}_k(\Omega)$ 

$$f(x) - \Pi_{V(X_n)}(f)(x) = \langle v_x - \Pi_{V(X_n)}(v_x), f \rangle = ||v_x - \Pi_{V(X_n)}(v_x)||$$

gilt, folgt

$$P_{V(X_n)}(x) = ||v_x - \Pi_{V(X_n)}(v_x)||.$$

Insbesondere gilt also

$$P_{V(X_0)}(x)^2 = ||k(\cdot, x)||^2 = \langle k(\cdot, x), k(\cdot, x) \rangle = k(x, x),$$

und ist also für translationsinvariante Kerne konstant, da  $k(x,x) = \phi(x-x) = \phi(0) \, \forall x \in \Omega$ .

Außerdem folgt

$$P_{V(X_n)}(x)^2 = \|k(\cdot, x) - \Pi_{V(X_n)}(k(\cdot, x))\|^2$$

$$= k(x, x) - \sum_{i=1}^n v_i(x)^2$$

$$= P_{V(X_0)}(x)^2 - \sum_{i=1}^n v_i(x)^2$$

$$= P_{V(X_{n-1})}(x)^2 - v_n(x)^2.$$

Wir bezeichnen das Residuum der n. Approximation mit

$$r_n(x) := f(x) - \prod_{V(X_n)} (f)(x)$$
  
=  $f(x) - \sum_{i=1}^n c_i v_i$   
=  $r_{n-1}(x) - c_n v_n$ .

Bei der iterativen Approximation gehen wir nun wie folgt vor. Wir konstruieren eine Orthonormalbasis  $(v_1, ..., v_n)$  der  $V(X_n)$ , die sich in jedem Iterationsschritt erweitern lässt. Dabei wählen wir in der n. Iteration das  $x_n$  aus  $\tilde{\Omega} \setminus X_{n-1}$  aus, das die Power function  $P_{V(X_{n-1})}(x)$  maximiert und orthogonalisieren  $k(\cdot, x_n)$  mithilfe des Gram-Schmidt-Verfahrens. Das bedeutet

$$x_1 = \underset{x \in \tilde{\Omega}}{\arg \max} \sqrt{k(x, x)}$$

$$v_1 = \frac{k(\cdot, x_1)}{\sqrt{k(x_1, x_1)}}$$

und

$$x_n = \underset{x \in \tilde{\Omega} \backslash X_{n-1}}{\arg \max} P_{V(X_{n-1})}(x)$$

$$v'_n = k(\cdot, x_n) - \sum_{i=1}^{n-1} \langle k(\cdot, x_n), v_i \rangle v_i$$

$$= k(\cdot, x_n) - \sum_{i=1}^{n-1} v_i(x_n) v_i$$

$$v_n = \frac{v'_n}{\|v'_n\|}.$$

Lemma 2. Es gilt

$$||v_n'|| = P_{V(X_{n-1})}(x)$$

Beweis.

$$||v_n'||^2 = \langle k(\cdot, x_n) - \sum_{i=1}^{n-1} v_i(x_n)v_i, k(\cdot, x_n) - \sum_{i=1}^{n-1} v_i(x_n)v_i \rangle$$

$$= k(x_n, x_n) - 2\sum_{i=1}^{n-1} v_i(x_n)^2 + \sum_{i=1}^{n-1} \sum_{j=1}^{n-1} v_i(x_n)v_j(x_n)\langle v_i, v_j \rangle$$

$$= P_{V(X_0)}(x_n)^2 - \sum_{i=1}^{n-1} v_i(x_n)^2$$

$$= P_{V(X_{n-1})}(x_n)^2.$$

Also ist

$$v_n = \frac{k(\cdot, x_n) - \sum_{i=1}^{n-1} v_i(x_n)v_i}{P_{V(X_{n-1})}(x_n)}.$$

**Lemma 3.** Für die Koeffizienten  $c_n$  der Approximation folgt

$$c_n = \langle f, v_n \rangle = \frac{r_{n-1}(x_n)}{P_{V(X_{n-1})}(x_n)}.$$

Beweis.

$$c_{n} = \langle f, v_{n} \rangle$$

$$= \langle f, \frac{k(\cdot, x_{n}) - \sum_{i=1}^{n-1} v_{i}(x_{n})v_{i}}{P_{V(X_{n-1})}(x_{n})} \rangle$$

$$= \frac{f(x_{n}) - \sum_{i=1}^{n-1} v_{i}(x_{n})\langle f, v_{i} \rangle}{P_{V(X_{n-1})}(x_{n})}$$

$$= \frac{f(x_{n}) - \sum_{i=1}^{n-1} c_{i}v_{i}(x_{n})}{P_{V(X_{n-1})}(x_{n})}$$

$$= \frac{r_{n-1}(x_{n})}{P_{V(X_{n-1})}(x_{n})}$$

## Implementierung

Grob ist die Implementierung wie folgt umgesetzt:

```
Initialisieren aller benötigten Größen;  \begin{aligned} & \textbf{for} \ i = 1,...,maxIter \ \textbf{do} \\ & & \text{Wähle argmax der Power Function aus;} \\ & \text{Berechne } i. \ \text{Basisfunktion } v_i \ \text{ausgewertet an Omega;} \\ & \text{Berechne } i. \ \text{Koeffizient } c_i \ \text{der Linearkombination bzgl. } v_i; \\ & \text{Aktualisiere die Residuen an Omega;} \\ & \text{Aktualisiere die Basiswechselmatrix;} \\ & \text{Aktualisierte die Power Function ausgewertet an Omega;} \\ & \textbf{if } \textit{Maximum der Power Function} < \textit{Toleranz then} \\ & \text{Speichere } i \ \text{als Anzahl benötigter Iterationen;} \\ & \text{break;} \\ & \textbf{end} \end{aligned}
```

end

Berechne die Approximation als  $\sum_i c_i v_i$  an Omega; Berechne die Koeffizienten  $\alpha_i$  für  $\sum_i \alpha_i k(\cdot, x_i)$  mittels der Basiswechselmatrix;

Sei  $f:\Omega\to\mathbb{R}^q$  und  $\tilde{\Omega}$  eine Diskretisierung von  $\Omega.$  Zur Implementierung notwendige Größen:

- $\tilde{\Omega} = \{x_1, ..., x_N\}$  Menge aller Punkte, aus denen wir  $\tilde{N}$  viele auswählen
- $A = (k(x_i, x_j))_{i,j=1,...,N}$

• 
$$f = \begin{pmatrix} f(x_1) \\ \vdots \\ f(x_N) \end{pmatrix} \in \mathbb{R}^{N \times q}$$
 die Auswertungen der zu approximierenden Funktion an  $\tilde{\Omega}$ 

Dabei wird im k. Schritt gespeichert:

•  $X_k := \{x_{j_1}, ..., x_{j_k}\} = X_{k-1} \cup \{x_{j_k}\}, J_k := \{j_1, ..., j_k\} = J_{k-1} \cup \{j_k\}$  die Auswahl von  $x_{j_k}$  aus  $\tilde{\Omega} \setminus X_{k-1}$ , sodass

$$x_{j_k} = \underset{x \in \tilde{\Omega} \backslash X_{k-1}}{\operatorname{arg \, max}} P_{V(X_{k-1})}(x).$$

• Eine Matrix der zu berechnenden Basisfunktionen ausgewertet an den ausgewählten Punkten  $x_{j_i} \in X_k$ , d.h.

$$V = \begin{pmatrix} \vdots \\ v_1(x_{j_3}) & v_2(x_{j_3}) & v_3(x_{j_3}) & 0 & \dots & 0 \\ \vdots & & & & & \\ v_1(x_{j_1}) & 0 & & & \dots & 0 \\ \vdots & & & & & \\ v_1(x_{j_2}) & v_2(x_{j_2}) & 0 & & \dots & 0 \\ \vdots & & & & & & \end{pmatrix} \in \mathbb{R}^{N \times \tilde{N}}$$

wobei  $V_{nm} = v_n(x_{j_m})$  für  $x_{j_m} \in X_k$ ,  $n \leq j_m$ . Im k. Schritt wird also die k. Spalte gesetzt:

$$V_{ik} = v_k(x_i) \quad \forall i \in \{1, ..., N\} \setminus X_k$$

Es ist

$$v_k(x_i) = \frac{k(x_i, x_{j_k}) - \sum_{j=1}^{k-1} v_j(x_{j_k}) v_j(x_i)}{P_{V(X_{k-1})}(x_{j_k})}$$

$$= \frac{A_{i,j_k} - \sum_{j=1}^{k-1} v_j(x_{j_k}) v_j(x_i)}{P_{V(X_{k-1})}(x_{j_k})}$$

mit

$$\sum_{j=1}^{k-1} v_j(x_{j_k}) v_j(x_i) = (v_1(x_{j_k}) \dots v_{k-1}(x_{j_k})) \cdot \begin{pmatrix} v_1(x_i) \\ \vdots \\ v_{k-1}(x_i) \end{pmatrix}.$$

V wird mit  $V = 0 \in \mathbb{R}^{N \times \tilde{N}}$  initialisiert.

 $\bullet\,$  Die Koeffizienten der Linearkombination von  $s_f^{(k)}$  :

$$c = \begin{pmatrix} c_1 \\ \vdots \\ c_k \\ 0 \\ \vdots \\ 0 \end{pmatrix} \in \mathbb{R}^{\tilde{N} \times q}$$

wobei  $c_k = \langle f, v_k \rangle = \frac{r_{k-1}(x_{j_k})}{P_{V(X_{k-1})}(x_{j_k})}$ . Es wird  $c := 0 \in \mathbb{R}^{\tilde{N} \times q}$  gesetzt.

• Das Residuum im k. Schritt ausgewertet an  $x_i \in \tilde{\Omega}$ , d.h

$$R^{(k)} = \begin{pmatrix} r_k(x_1) \\ \vdots \\ r_k(x_N) \end{pmatrix} \in \mathbb{R}^{N \times q}$$

wobei  $r_k(x_{j_i}) = 0 \quad \forall i \in J_k$ . Dabei wird wie folgt aktualisiert:

$$r_k(x_i) = r_{k-1}(x_i) - c_k v_k(x_i) \quad \forall i \in \{1, ..., N\} \setminus X_{k-1}.$$

Es wird  $R^{(0)} = f \in \mathbb{R}^{N \times q}$  initialisiert.

• Die Power Function ausgewertet an den Punkten  $x_i \in \tilde{\Omega}$ 

$$P^{(k)} = \begin{pmatrix} P_{V(X_k)}(x_1) \\ \vdots \\ P_{V(X_k)(x_N)} \end{pmatrix},$$

wobei  $P_{V(X_k)}(x_i) = 0 \quad \forall i \in J_k$ . Dabei wird wie folgt aktualisiert:

$$P_{V(X_k)}(x_i) = \sqrt{P_{V(X_{k-1})}(x_i)^2 - v_{j_k}(x_i)^2} \quad \forall i \in \{1, ..., N\} \setminus X_{k-1}.$$

Es wird

$$P^{(0)} = \begin{pmatrix} P_{V(X_0)}(x_1) \\ \vdots \\ P_{V(X_0)(x_N)} \end{pmatrix} = \begin{pmatrix} k(x_1, x_1) \\ \vdots \\ k(x_1, x_1) \end{pmatrix}$$

gesetzt.

• Die Basiswechselmatrix  $T=(d_{ij})_{i,j=1,...,\tilde{N}}$  von  $(v_1,...,v_{\tilde{N}})$  zu  $(k(\cdot,x_{j_1}),...,k(\cdot,x_{j_{\tilde{N}}}))$ , wobei

$$v_j = \sum_{i=0}^{\tilde{N}} d_{ij} k(\cdot, x_{j_i}) = \sum_{i=0}^{j} d_{ij} k(\cdot, x_{j_i}) \quad \forall j = 1, \dots, \tilde{N}.$$

 $\operatorname{Im} k$ . Schritt wird also die k. Spalte gesetzt mit

$$d_{lk} = -\frac{1}{P_{V(X_{k-1})}(x_{j_k})} (d_{l1} \dots d_{l,k-1}) \cdot \begin{pmatrix} v_1(x_{j_k}) \\ \vdots \\ v_{k-1}(x_{j_k}) \end{pmatrix}$$
$$= -\frac{1}{P_{V(X_{k-1})}(x_{j_k})} \sum_{i=1}^{k-1} v_i(x_{j_k}) d_{li} \quad \forall l < k$$

und  $d_{kk} = \frac{1}{P_{V(X_{k-1})}(x_{j_k})}$ ,  $d_{lk} = 0$  falls l > k, da

$$v'_{k} = k(\cdot, x_{j_{k}}) - \sum_{i=1}^{k-1} v_{i}(x_{j_{k}})v_{i}$$

$$= k(\cdot, x_{j_{k}}) - \sum_{i=1}^{k-1} v_{i}(x_{j_{k}}) \sum_{l=1}^{i} d_{li}k(\cdot, x_{j_{l}})$$

$$= k(\cdot, x_{j_{k}}) - \sum_{i=1}^{k-1} \sum_{l=1}^{k-1} v_{i}(x_{j_{k}})d_{li}k(\cdot, x_{j_{l}})$$

$$= k(\cdot, x_{j_{k}}) - \sum_{l=1}^{k-1} \sum_{i=1}^{k-1} v_{i}(x_{j_{k}})d_{li}k(\cdot, x_{j_{l}})$$

und

$$v_k = \frac{v_k'}{P_{V(X_{k-1})}(x_{j_k})}.$$

Initialisiert wird T mit

$$T = 0 \in \mathbb{R}^{\tilde{N} \times \tilde{N}}.$$